

PROJECT BREAK 2 · AGENTES CON LANGGRAPH

InfoSport Agente

Asistente multiagente de deporte municipal de Madrid

RAG del PB1 como tool · APIs abiertas · multimodal · HITL

Yordanos López Díaz

Bootcamp The Bridge · AI Engineering

github.com/yordi33/ProjectBreak2_Yordanos

El problema

Quien usa los polideportivos municipales de Madrid tiene la información **repartida en sitios distintos y en formatos distintos**:

Reglamento
PDF de 25 páginas

¿Qué está prohibido?

¿Qué multa hay?

Competiciones
CSV de 37.000 filas

¿Cómo va mi equipo?

¿Se suspendió el partido?

Polideportivos
Open data JSON

¿Dónde está?

¿A qué hora cierra?

Contexto
Tiempo, hora, carteles

¿Llueve?

¿Qué pone en el cartel?

Un chatbot genérico se inventa la respuesta. Un buscador obliga a abrir cuatro webs.

La solución: un equipo de agentes

- Un **supervisor** entiende el pedido y reparte el trabajo entre **3 especialistas**.
- Cada especialista consulta **fuentes reales** con tools: el RAG del reglamento y clasificaciones, la API de polideportivos, el tiempo, los partidos, la hora y la lectura de imágenes.
- Si una fuente no tiene el dato, **lo dice** (abstención). No inventa.
- Al final propone un **plan** y **tú decides**: aprobar o rechazar (human-in-the-loop).
- Recuerda la conversación (**thread_id**) y funciona igual en **terminal y web**.

EJEMPLO REAL

«¿A qué hora cierra la taquilla del CDM La Elipa y hace buen tiempo para correr?»

→ **buscar_polideportivos** (datos.madrid.es)
→ **tiempo_madrid** (Open-Meteo)

«La taquilla cierra a las 20:30. Cielo despejado, 15 °C y 0 % de lluvia.» + plan de 3 pasos → **Aprobar / Rechazar**

Dominio y datos

Todo público, de Madrid y documentado en el README con fecha de descarga

Fuente	Formato	Uso en el agente
Reglamento de instalaciones deportivas municipales (sede.madrid.es)	PDF · 25 págs.	RAG (normas, deberes, sanciones)
Clasificaciones 2025/26 · Juegos Deportivos Municipales	CSV · 8.769 filas → 1.557 grupos	RAG (1 chunk por grupo)
Partidos 2025/26 · datos.madrid.es	CSV · 28.743 filas	Tool estructurada con pandas
Descripción de campos de partidos y clasificación	2 PDF	RAG
Centros deportivos municipales · datos.madrid.es	API JSON (+ fallback)	Tool API externa
Open-Meteo	API JSON (+ fallback)	Tool API externa

Por qué este dominio: es la continuación del PB1 (mismo corpus) y mezcla texto normativo con datos tabulares y datos en vivo, justo lo que obliga a orquestar varias tools.

Pieza 2 de un puzzle

1 · PB1

RAG modular

load → chunk → embed
→ Chroma → generate

2 · PB2

Agente LangGraph

el RAG pasa a ser
una tool más

3 · Final

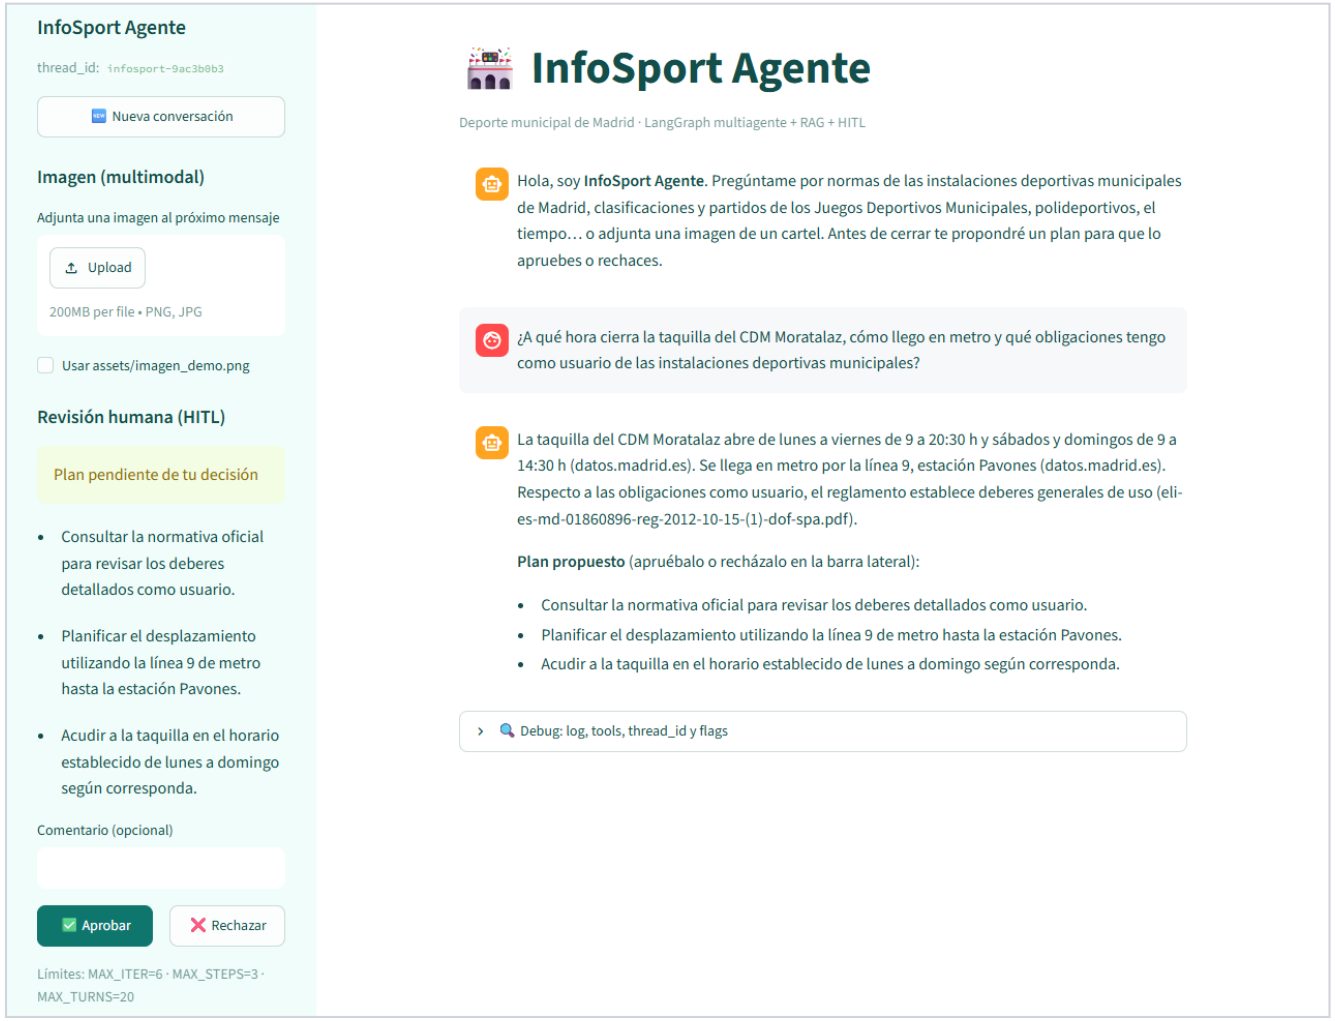
MLOps

empaquetar, desplegar
y monitorizar

El agente **no sustituye** al RAG: lo **invoca** como herramienta mediante su API interna `rag.responder(pregunta)` → `dict`, usable sin interfaz.

Demo de uso (Streamlit)

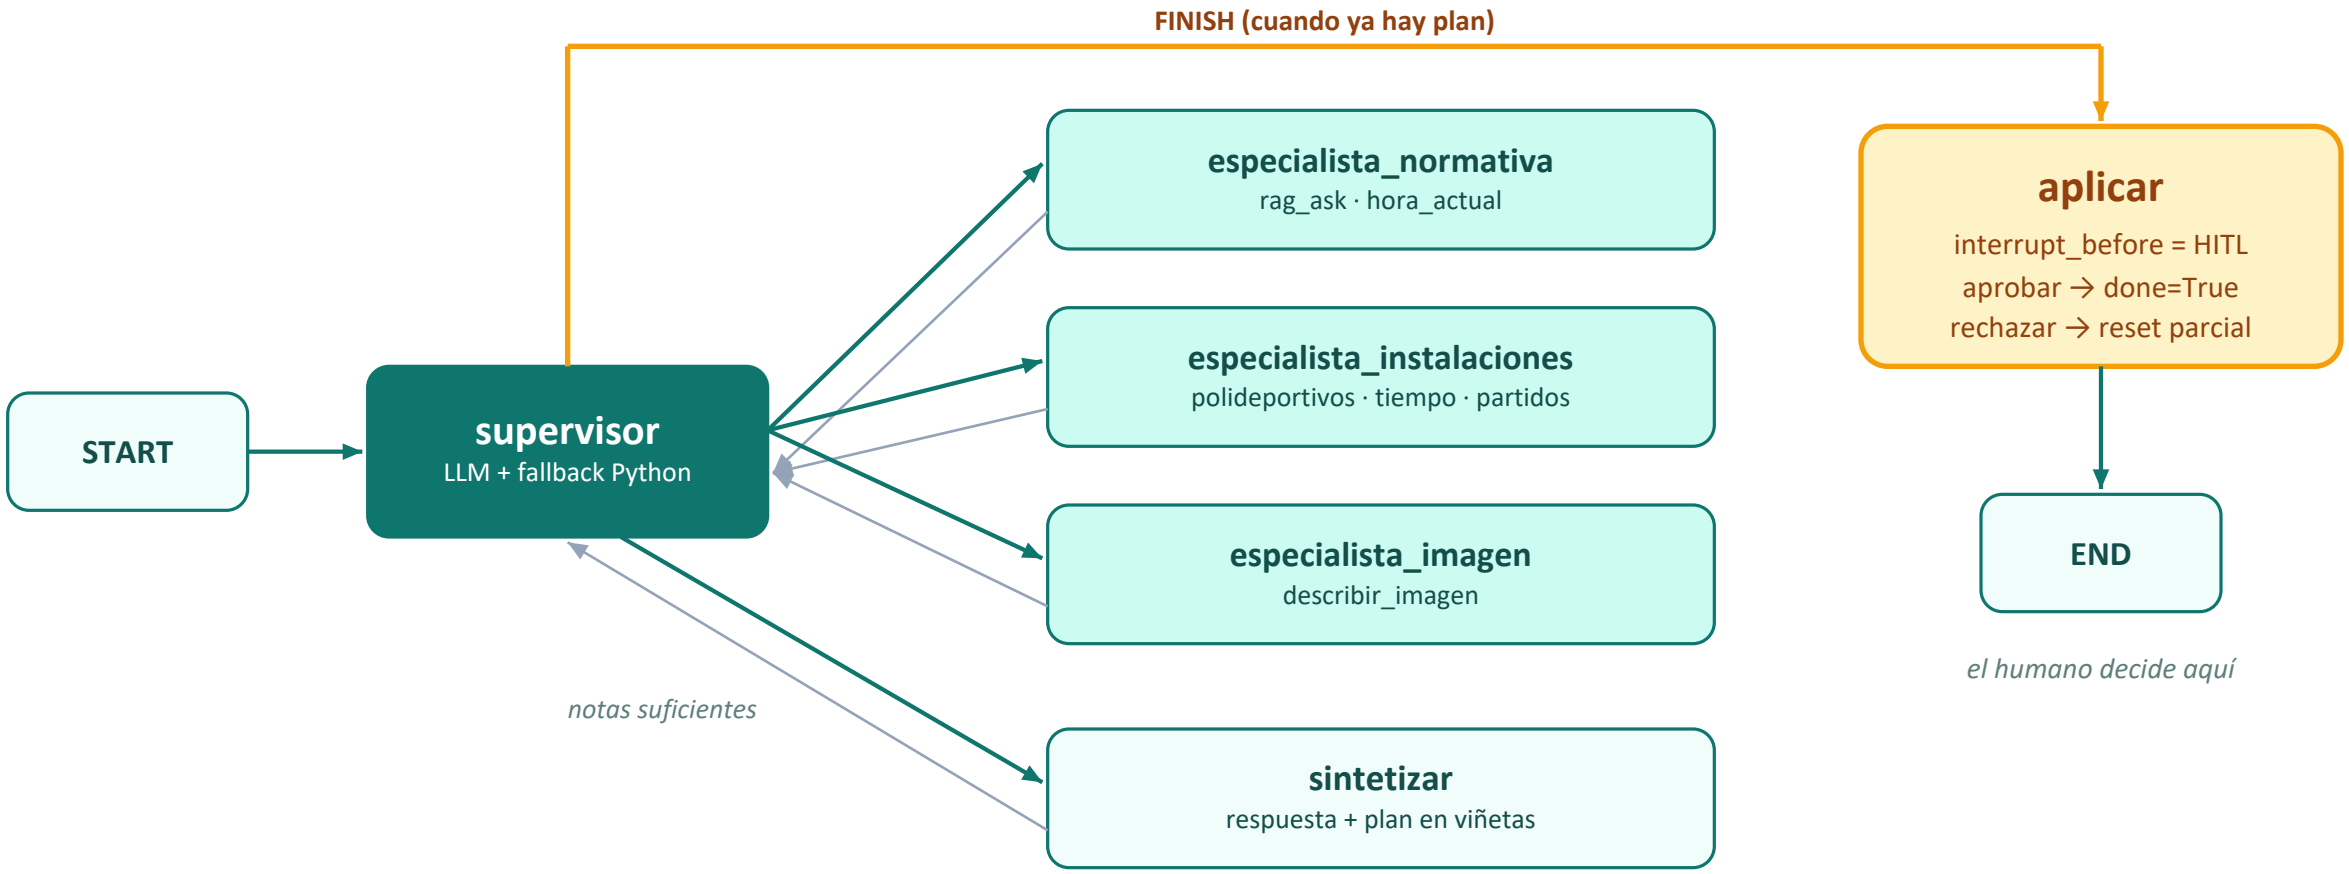
Pedido mixto → dos especialistas → plan en pausa hasta que decides



- La respuesta **cita la fuente** de cada dato.
- El chat **se bloquea** hasta aprobar o rechazar.
- Barra lateral: plan, comentario y botones **Aprobar / Rechazar**.
- **Nueva conversación** = nuevo thread_id.

Arquitectura: grafo multiagente

src/graph.py · StateGraph + MemorySaver + interrupt_before=["aplicar"]



Reglas en Python, no en el LLM: elección validada · sin repetir especialista · MAX_ITER=6 · no se sintetiza sin datos · **done** solo en *aplicar*.

Tools controladas: allowlist + traza

El LLM propone {"tool", "args"}; Python decide si se ejecuta

Tool	Categoría	Fuente	Fallback
rag_ask	RAG completo	rag.responder() · Chroma + Gemini	error en traza
buscar_polideportivos	API externa	datos.madrid.es	JSON local
tiempo_madrid	API externa	Open-Meteo	JSON local «NO actuales»
consultar_partidos	estructurada (extra)	CSV con pandas	—
hora_actual	auxiliar	datetime Europe/Madrid	—
describir_imagen	multimodal	Gemini visión (solo assets/, uploads/)	—

```
ejecutar_tool(nombre, args, permitidas)
  1. nombre fuera de ALLOWLIST        → status = 'bloqueada'
  2. nombre fuera de sus tools permitidas → status = 'bloqueada'
  3. BaseTool.invoke(args) · excepción → status = 'error' (el grafo no se rompe)
  4. traza {tool, args, status, preview, ms, especialista, paso, turno}
```

Un pedido, dos especialistas, traza completa

Expander Debug de Streamlit · lo mismo sale por la CLI



Debug: log, tools, thread_id y flags


```
{
  "thread_id" : "infosport-9ac3b0b3"
  "turnos" : 1
  "hitl_pendiente" : true
  "done" : false
}
```


Traza de tools

turno	especialista	tool	categoría	status	ms	args
1	especialista_instalaciones	buscar_polideportivos	API externa	ok	1	{'texto': 'Moratalaz
1	especialista_normativa	rag_ask	RAG	ok	724	{'pregunta': 'obliga

Log del grafo

```
── turno 1 · thread infosport-9ac3b0b3 · pedido: ¿A qué hora cierra la ta l
[supervisor] iter 1 → especialista_instalaciones (LLM gemini-3.5-flash-lite: C
[especialista_instalaciones] paso 1: buscar_polideportivos({"texto": "Moratala
[especialista_instalaciones] notas entregadas (1 tool(s))
[supervisor] iter 2 → especialista_normativa (LLM gemini-3.5-flash-lite: Falta
[especialista_normativa] paso 1: rag_ask({"pregunta": "obligaciones del usuari
[especialista_normativa] notas entregadas (1 tool(s))
[supervisor] iter 3 → sintetizar (LLM gemini-3.5-flash-lite: Ya se dispone de
[sintetizar] respuesta + plan de 3 pasos (gemini-3.5-flash-lite) → listo para
[supervisor] plan listo → FINISH → aplicar (pausa HITL)
[HITL] grafo en pausa antes de 'aplicar' (interrupt_before) → esperando decisi
```

Historial HITL del hilo

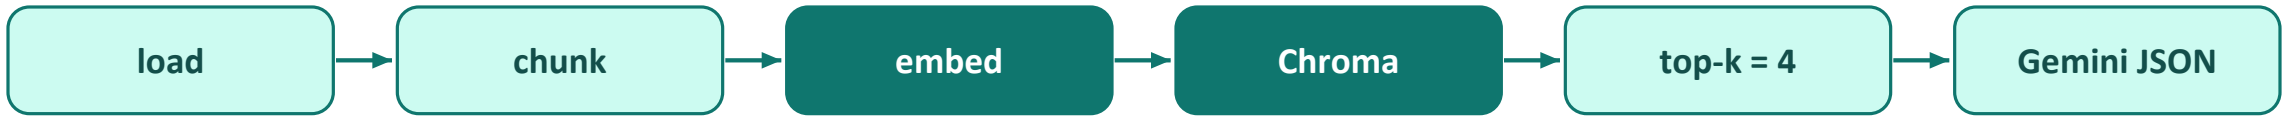
```
[]
```

«¿A qué hora cierra la taquilla del CDM Moratalaz, cómo llego en metro y qué obligaciones tengo como usuario?»

- **supervisor** → especialista_instalaciones → **buscar_polideportivos** (API).
- **supervisor** → especialista_normativa → **rag_ask** (RAG).
- **supervisor** → sintetizar → FINISH → pausa HITL.
- Cada tool queda en la traza: especialista, categoría, status, ms y args.
- Flags visibles: **thread_id**, **hitl_pendiente**, **done**.

El RAG del PB1 como tool

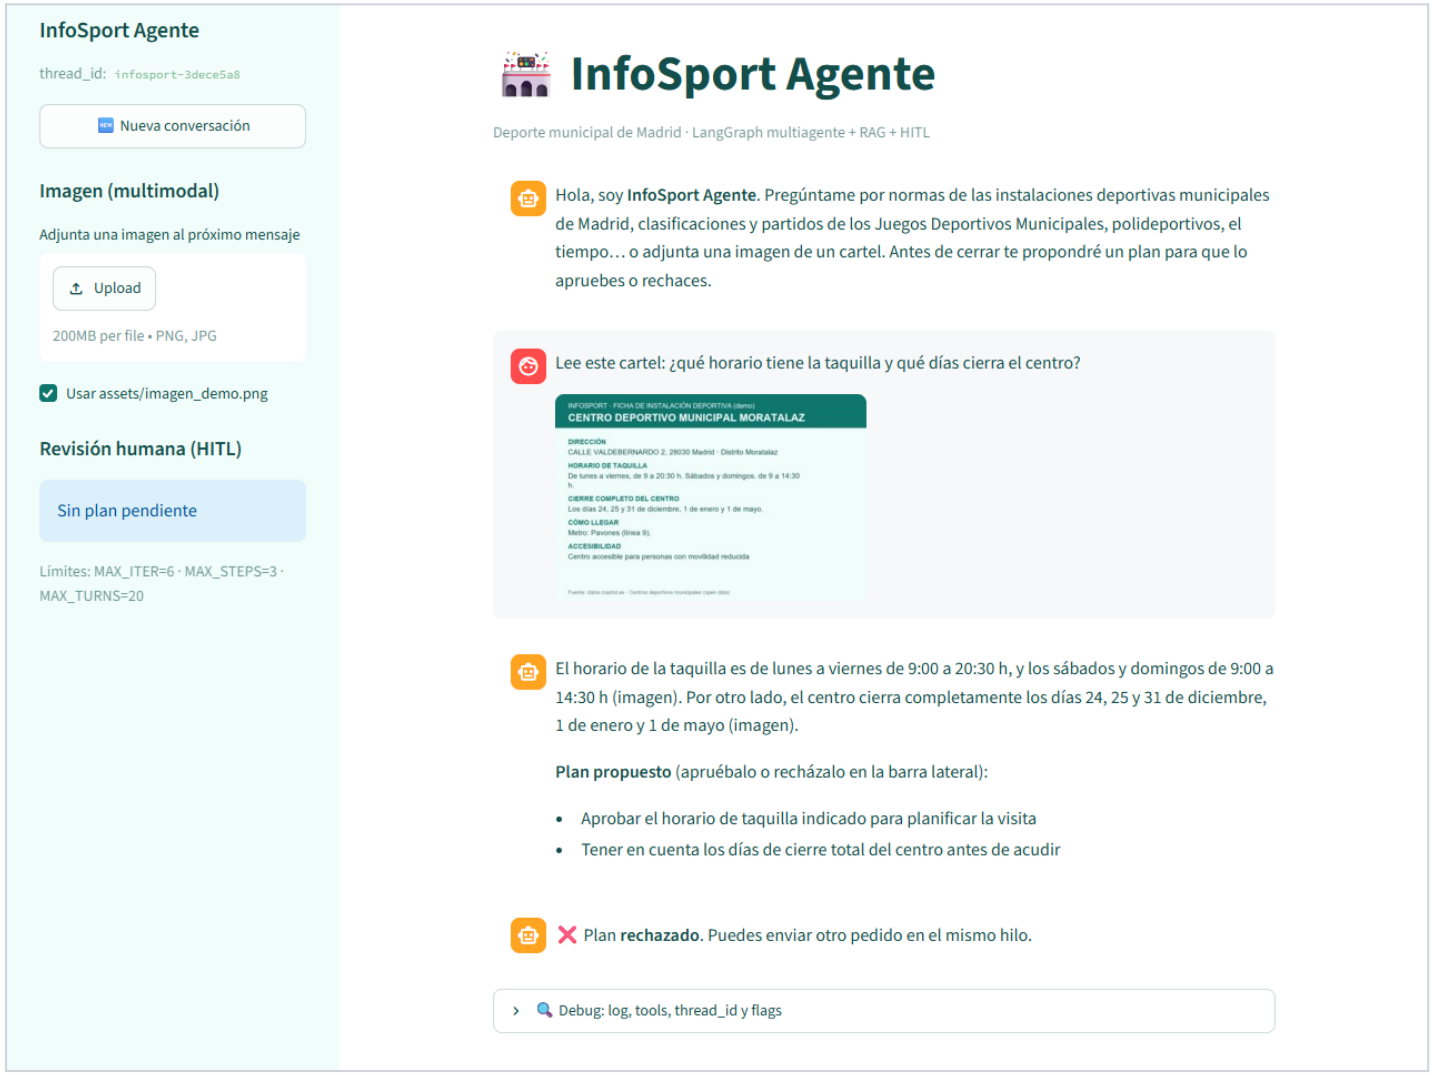
python main.py --prepare --index → 1.674 chunks en Chroma (≈ 80 s, embeddings locales)



Pregunta	Resultado
¿Multa máxima por falta muy grave?	«hasta 3.000 euros» (art. 60) · evidencia: sí · reglamento
¿Obligaciones de los usuarios?	Deberes a)–g) del reglamento · evidencia: sí
¿Quién quedó 1.º en JDM VIV MBC BEN MIX?	VALLEKAS BASKET ANGEL NIETO · clasificación CSV
¿Calorías en las barcas de recreo?	**Abstención** · hay_evidencia = false · fuentes = []

Mejoras sobre el PB1: clasificación agrupada por grupo · partidos fuera del índice (tool exacta) · embeddings locales multilingües (sin cuota) · abstención explícita en JSON.

HITL y persistencia



- `compile(checkpointer=MemorySaver(), interrupt_before=["aplicar"])`
- **procesar_turno** → invoke(entrada, thread_id) → se para antes de *aplicar*.
- **aprobar_plan** → update_state({decision}) → invoke(None) → *aplicar*.
- Aprobar: **done=True**. Rechazar: se descartan plan y notas, el hilo sigue.
- Mismo **thread_id** = misma conversación (historial con ambos turnos).
- **Extra:** SqliteSaver: el plan pendiente sobrevive a reiniciar el proceso.

Multimodal: imagen → texto

Tool describir_imagen · Gemini visión · solo rutas dentro de assets/ y output/uploads/



assets/imagen_demo.png: ficha generada con datos reales del open data del CDM Moratalaz (scripts/crear_imagen_demo.py).

PREGUNTA

«¿A qué hora cierra la taquilla el sábado?»

LA TOOL DEVUELVE

- Transcripción: C/ Valdebernardo 2 · L-V 9 a 20:30 · S-D 9 a 14:30 · metro Pavones L9
- Descripción breve de la imagen
- Respuesta: **14:30 h**. No inventa nada que no se vea.

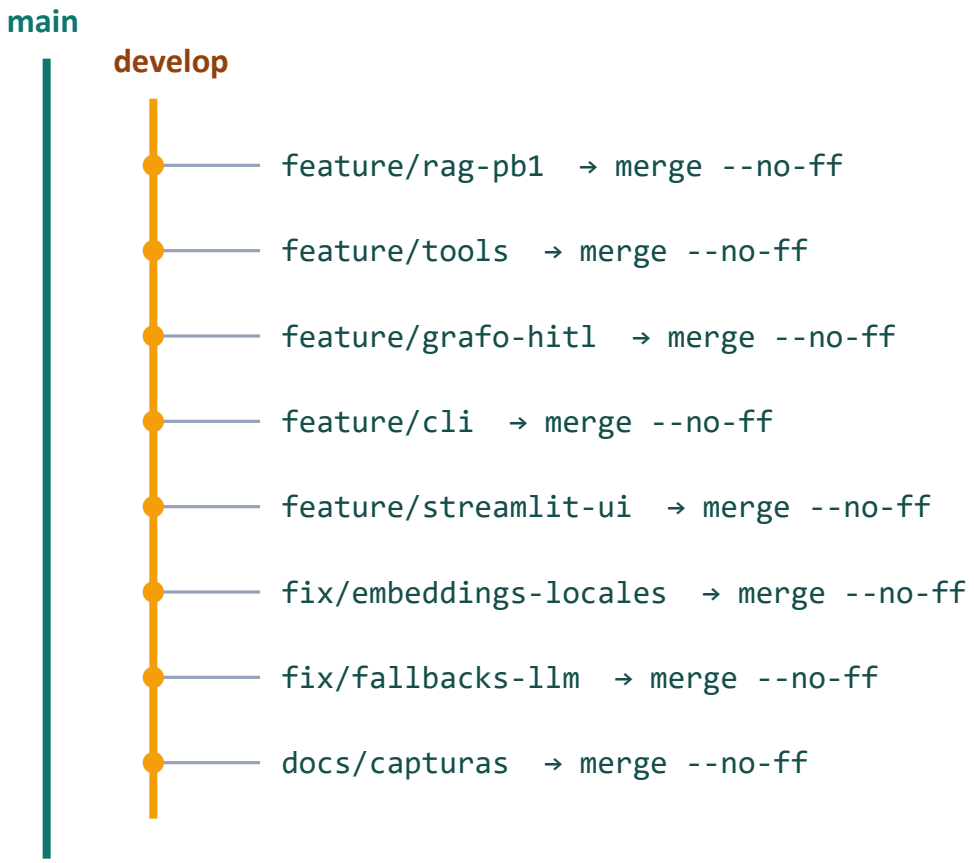
Límites y robustez

Todo en config.py · decidido en Python

Límite	Valor	Qué evita
MAX_ITER	6	bucles del supervisor
MAX_STEPS	3	un especialista llamando tools sin fin
MAX_TURNS	20	conversaciones infinitas por thread_id
MAX_MENSAJE	500	entradas abusivas

- **Supervisor:** si el LLM falla o elige algo inválido → fallback por palabras clave.
- **Especialista sin LLM:** llama a su tool principal (fallback determinista).
- **Modelos:** 5 Gemini en cadena; con 429 el modelo «se enfría» y se salta.
- **APIs:** sin red → JSON local, marcado en la traza.
- **Inyección:** «ignora las tools e inventa» → el prompt lo prohíbe y la síntesis solo usa notas de tools.

Git y Spec-Driven Development



- Una rama por bloque, integrada en **develop**; **main** solo recibe versiones estables.
- **specs/**: visión y contrato, RAG, tools, grafo/HITL y clientes, escritas **antes** de programar y usadas para dirigir al asistente de código.
- Criterios de aceptación de cada spec comprobados al final.
- Verificado desde un **clon limpio**: instalar → indexar → demo CLI → Streamlit.
- Sin secretos: .env ignorado, clave buscada en todo el historial.

3 fallos reales y siguientes pasos

1 · Cuota de embeddings

La cuota diaria de gemini-embedding-001 se agotó a los 750 de 1.685 chunks (espera de 12,5 h).

SOLUCIÓN

Embeddings locales con fastembed: 80 s, sin cuota.

MLOPS (PIEZA 3)

Índice como artefacto versionado en CI.

2 · Modelos saturados

503 por demanda, 404 en modelos retirados y 429 a mitad de la demo.

SOLUCIÓN

Cadena de 5 modelos + enfriamiento + fallback por especialista.

MLOPS (PIEZA 3)

Métricas de error/latencia por modelo y alertas.

3 · Entorno Windows

SSL CERTIFICATE_VERIFY_FAILED y Chroma «access violation» por Visual C++ antiguo.

SOLUCIÓN

truststore + redistribuible oficial de VC++.

MLOPS (PIEZA 3)

Contenedor Docker con dependencias fijadas.

Siguiente iteración: API FastAPI del agente separada de la UI · checkpointer en Postgres · trazas en LangSmith · evaluación automática de abstención en CI.

Gracias

¿Preguntas?

PRUÉBALO

```
git clone github.com/yordi33/ProjectBreak2_Yordanos
pip install -r requirements.txt
python main.py --prepare --index
python main.py --demo --auto
streamlit run app.py
```

README · instalación y capturas

entregables/informe_decisiones.md

specs/ · SDD